

Phân tích và Dự đoán Lượng Khách Du Lịch Quốc tế Đến Việt Nam

Báo cáo Cuối Kỳ — Lập trình Phân tích Dữ liệu với Python

dnng-nguyn

Tháng 7, 2025

1 Mục lục

1. Giới thiệu đề tài
2. Thu thập dữ liệu
3. Tiền xử lý dữ liệu
4. Phân tích và khám phá dữ liệu (EDA)
5. Xây dựng mô hình dự đoán
6. Tối ưu mô hình
7. Dự đoán tương lai
8. Tổng kết

2 1. Giới thiệu đề tài

2.1 1.1 Đặt vấn đề bài toán

Du lịch là một trong những ngành kinh tế quan trọng của Việt Nam, đóng góp đáng kể vào GDP và tạo ra hàng triệu việc làm. Trong những năm gần đây, Việt Nam đã nổi lên như một điểm đến hấp dẫn trong khu vực Đông Nam Á, thu hút lượng lớn khách quốc tế từ nhiều quốc gia khác nhau.

Tuy nhiên, lượng khách du lịch quốc tế chịu ảnh hưởng của nhiều yếu tố phức tạp: tình hình kinh tế toàn cầu, chính sách visa, tỷ giá hối đoái, sự cạnh tranh từ các quốc gia láng giềng, và các cú sốc bên ngoài như đại dịch COVID-19 (2020-2021). Việc hiểu rõ các xu hướng, mô hình mùa vụ, và mối quan hệ giữa các thị trường nguồn là điều cần thiết để hoạch định chiến lược du lịch hiệu quả.

Một thách thức quan trọng trong bộ dữ liệu này là **sự không đồng đều về số quốc gia báo cáo qua các năm**: chỉ 12 quốc gia báo cáo trong giai đoạn 2009-2011, so với 30+ quốc gia từ 2012 trở đi. Điều này có nghĩa là tổng số liệu thô bị ảnh hưởng bởi sự thay đổi phạm vi báo cáo, không chỉ bởi tăng trưởng thực tế. Báo cáo này giải quyết vấn đề này một cách rõ ràng.

2.2 1.2 Mục tiêu đề tài

Mục tiêu phân tích: - Analyze overall trends in international arrivals to Vietnam (2008-2026) - Identify top source countries and their changing rankings - Detect seasonal patterns in quarterly arrivals - Analyze correlations between source markets - Assess the impact of COVID-19 on Vietnam's tourism sector - Evaluate average annual growth rates, accounting for coverage gaps

Mục tiêu dự đoán: - Build machine learning models to predict quarterly arrivals - Compare Linear Regression, Random Forest, XGBoost, SARIMA, and Chronos-T5 - Tune hyperparameters to improve model accuracy - Forecast arrivals for the next 4 quarters with confidence intervals - Evaluate the CIR# stochastic model (from academic literature) and explain why it does not fit this dataset

2.3 1.3 Phạm vi và nguồn dữ liệu

- **Đối tượng phân tích:** Lượng khách quốc tế đến Việt Nam, phân theo quốc gia nguồn và theo quý (Q1-Q4)
- **Thời gian:** 2008-2026, lưu ý năm 2021 không có dữ liệu (ảnh hưởng COVID-19)
- **Quốc gia:** 32 quốc gia riêng lẻ (không bao gồm tổng hợp khu vực như “Các thị trường khác thuộc châu Á”)
- **Nguồn dữ liệu:** Bốn file báo cáo HTML-Excel (.xls) từ Tổng cục Thống kê Việt Nam

2.4 1.4 Công cụ và thư viện sử dụng

- **Ngôn ngữ lập trình:** Python 3
- **Xử lý dữ liệu:** pandas, numpy, lxml (phân tích HTML)
- **Trực quan hóa:** matplotlib, seaborn
- **Xây dựng mô hình:** scikit-learn, xgboost, statsmodels (SARIMA), chronos-forecasting (Chronos-T5)
- **Môi trường:** Jupyter Notebook
- **Quản lý phiên bản:** Git, GitHub

3 2. Thu thập dữ liệu

3.1 2.1 Nguồn dữ liệu

The data consists of 4 HTML-Excel report files, each containing international tourist arrivals for one quarter:

File	Quarter	Notes
quy1-cacnuoc.xls	Q1	Starts from 2009
quy2-cacnuoc.xls	Q2	Starts from 2009
quy3-cacnuoc.xls	Q3	Starts from 2008
quy4-cacnuoc.xls	Q4	Starts from 2008

3.2 2.2 Cấu trúc dữ liệu và thách thức

Các file `.xls` không phải là file Excel nhị phân thực sự — chúng là file HTML có phần mở rộng `.xls`, một kỹ thuật phổ biến để tạo file “Excel” từ ứng dụng web. Cấu trúc HTML có một số thách thức:

1. **Text nodes nằm ngoài thẻ `<td>`:** Numeric values appear as text between empty `<td>` elements rather than inside them. Standard parsers like `pd.read_html()` return all NaN values. A custom `lxml`-based parser was built to extract data from text nodes.
2. **Phạm vi năm không đồng nhất:** Q3/Q4 files include 2008 data; Q1/Q2 start from 2009. The year 2021 is absent from all files (COVID-19 lockdown).
3. **Định dạng số tiếng Việt:** Dots serve as thousands separators (e.g., `104.520` = 104,520), not decimal points.
4. **Tổng hợp khu vực trộn lẫn với quốc gia:** The 2008 file includes entries like “Chau A” (Asia), “Chau Au” (Europe), and “Other markets” alongside individual countries. These were excluded from analysis.

3.3 2.3 Cách xử lý và hợp nhất dữ liệu

A custom HTML parser using `lxml` was built: - Parse the DOM tree and extract year labels from the header row (columns 2+) - For each data row, extract country name from `td[0].tail` and values from `td[1:].tail` - Convert Vietnamese-formatted numbers by removing dot separators - Merge all 4 files into a single DataFrame with columns: `country`, `year`, `quarter`, `arrivals`

Verification: “USA” for 2009 Q1 = 104,520 — confirmed against the provided sample.

After parsing: **1,622 records**, **32 individual countries**, years 2008-2026.

3.4 2.4 Vấn đề phủ sóng quốc gia

Một phát hiện quan trọng là số quốc gia báo cáo không đồng đều giữa các năm:

Year	Countries Reporting	Note
2008	29	Q3/Q4 only (different file structure)
2009-2011	11-12	Only Q1/Q2 files, severely limited
2012-2015	29-30	Stable coverage
2016-2026	29-35	Near-complete coverage

Điều này có nghĩa là **tổng số liệu giai đoạn 2009-2011 bị thấp một cách giả tạo** vì chỉ 11-12 quốc gia đang báo cáo. Sự “tăng trưởng” rõ ràng từ 2.65M (2009) lên 18M (2019) một phần do nhiều quốc gia được bổ sung vào bộ dữ liệu hơn, không chỉ do tăng trưởng hữu cơ.

Để giải quyết vấn đề này, báo cáo sử dụng **tỷ lệ tăng trưởng hàng năm trung bình** (theo từng quốc gia, ít bị ảnh hưởng bởi phạm vi báo cáo) bên cạnh tổng số liệu thô.

4 3. Tiền xử lý dữ liệu

4.1 3.1 Làm sạch dữ liệu

- **Loại bỏ tổng hợp khu vực:** “Chau A”, “Chau Au”, “Other markets by continent” entries were excluded. These are summary rows, not individual countries.
- **Loại bỏ hàng “Totals”:** Summary total per year-quarter.
- **Không tìm thấy bản ghi trùng lặp.**
- **Tên quốc gia giữ nguyên tiếng Việt** trong notebook; chuyển sang tiếng Anh cho báo cáo này.

4.2 3.2 Xử lý giá trị thiếu

Khoảng trống 2021 (không có dữ liệu) được xử lý bằng cách loại bỏ 2021 khỏi chuỗi thời gian. For the feature grid, missing country-year-quarter combinations were filled with 0.

4.3 3.3 Trích xuất đặc trưng (Feature Engineering)

- **Time features:** `quarter_num` (1-4), `time_idx` (`year + quarter/4`)
- **Lag features:** `lag_1` (previous quarter), `lag_2`, `lag_4` (same quarter last year)
- **Rolling mean:** 4-quarter rolling average to smooth short-term fluctuations
- **External features:** Exchange rates (Yahoo Finance), visa policy indicators (manually encoded from government sources)

4.4 3.4 Chia tập train/test

- **Training set:** Data up to and including 2023
- **Test set:** 2024 onward (2024 Q1 through 2026 Q2 = 10 quarters)

5 4. Phân tích và khám phá dữ liệu (EDA)

5.1 4.1 Xu hướng tổng thể với bối cảnh phủ sóng




Figure 1: Figure 1: Total arrivals by year with country count overlay

The bar chart (gray, secondary axis) shows the number of reporting countries per year. Key observations:

- **2009-2011:** Only 11-12 countries report, making totals appear artificially low (~2.6-4.0M)
- **2012+:** Coverage stabilizes at 29-30 countries, enabling fair comparison
- **2020:** Sharp COVID-19 drop to ~3.7M despite full coverage (30 countries)
- **2025:** Recovery to ~17.6M with 29 countries — genuine growth

Important: The “growth” from 2009 to 2012 should not be interpreted at face value — it’s largely a coverage artifact.

5.2 4.2 Tỷ lệ tăng trưởng hàng năm trung bình

To compare countries fairly regardless of absolute volume, average annual growth rates were computed for 2012-2019 (pre-COVID, stable coverage):

Growth rates reflect **emerging markets** (Hong Kong, Spain, Italy, Germany, Philippines) rather than established markets. China and South Korea — the two largest markets — grew at more moderate rates from a high base.

5.3 4.3 Các quốc gia nguồn hàng đầu theo khối lượng

China (41.7M cumulative) and South Korea (33.0M) dominate. However, these totals span all years including the coverage-limited 2009-2011 period, so they slightly undercount for countries missing early data.

5.4 4.4 Tính mùa vụ

- **Q1** has the highest average arrivals (Tet holiday, New Year tourism)
- **Q4** has the highest variance, suggesting year-end tourism depends heavily on specific conditions




Figure 2: Figure 2: Top countries by average annual growth rate




Figure 3: Figure 3: Top 10 source countries (all years combined)




Figure 4: Figure 4: Average arrivals by quarter

5.5 4.5 Tương quan giữa các thị trường nguồn

- **China-Taiwan** correlation: 0.89 (shared geography, similar travel patterns)
- **USA** has low correlation with Asian markets (independent dynamics, affected by USD/VND exchange rate)

5.6 4.6 Xu hướng theo từng quốc gia

- **South Korea** recovered fastest post-COVID
- **China** suffered the steepest drop and slowest recovery
- **Japan** shows steady but slower growth




Figure 5: Figure 5: Correlation between top 5 source countries




Figure 6: Trends for top 5 source countries

6 5. Xây dựng mô hình dự đoán

Five models were tested on aggregate quarterly arrivals (all countries summed). All use features: year, quarter number, time index, lag_1, lag_4, rolling_mean_4.

6.1 5.1 Linear Regression (Hồi quy tuyến tính)

Linear Regression assumes a linear relationship between features and target. It finds the best-fitting line by minimizing sum of squared errors.

Despite its simplicity, LR captures the overall upward trend effectively.

6.2 5.2 Random Forest Regression

Random Forest combines many decision trees, each trained on a bootstrap sample. Predictions are averaged across trees, reducing overfitting compared to a single tree.

6.3 5.3 XGBoost Regressor

XGBoost builds trees sequentially, each correcting the errors of the previous one. Known for strong performance in competitions.

6.4 5.4 SARIMA (Mô hình chuỗi thời gian)

SARIMA combines autoregressive (AR), differencing (I), moving average (MA), and seasonal components. The year 2021 gap was removed from the training series.

6.5 5.5 Chronos-T5 (Foundation Model)

Chronos is Amazon’s pretrained time-series foundation model. It performs **zero-shot forecasting** — no task-specific training needed. Four sizes were tested (Tiny/Small/Base/Large); Base (200M params) gave the best MAE.

6.6 5.6 CIR# — Mô hình phương trình vi phân ngẫu nhiên (Đã xem xét nhưng không áp dụng)

The CIR# (Cox-Ingersoll-Ross Sharp) model from Clements et al. (2023) extends the classic CIR SDE for tourism forecasting with disrupted data. It achieved MAPE 1.18% on Italian monthly tourism data — a 70% error reduction vs SARIMA and Holt-Winters.

Why CIR# does not fit this dataset:

1. **Insufficient observations:** Only 55 quarterly data points (vs 288 monthly in the Italian study). The rolling window of $M=8$ consumes 15% of data.
2. **Mean-reversion assumption violated:** The CIR SDE pulls toward a long-run mean. Vietnam’s tourism has a strong upward trend that contradicts mean-reversion.
3. **COVID shock magnitude:** An 80% drop followed by full recovery causes the $\sqrt{r}$ volatility term to amplify noise in log-returns, producing wild oscillations.
4. **Quarterly vs monthly granularity:** The original paper’s success relied on monthly data providing more observations per window and better seasonal capture.

CIR# achieved MAPE ~183% on this data — far worse than all other models. This is an honest negative result: **not every state-of-the-art model fits every dataset**. CIR# is designed for stationary, mean-reverting processes (interest rates, short-term economic indicators), not for trending series with structural breaks.




Figure 7: Figure 7: Model performance comparison

6.7 5.7 So sánh hiệu suất các mô hình

Model	MAE	RMSE	MAPE	R ²
Linear Regression	668,001	826,017	14.96%	-0.11
Random Forest	718,697	943,153	14.73%	-0.44
Chronos-T5-Base	760,788	970,698	15.42%	-0.53
XGBoost	983,132	1,396,363	21.32%	-2.16
SARIMA	2,191,581	2,369,273	47.23%	-8.10

Key observations:

- All R^2 values are **negative**, meaning every model performs worse than predicting the mean. This is expected — the post-COVID surge is a structural break invisible to history-based models.
- **Linear Regression** has the lowest MAE (668K) and best R^2 (-0.11). Its linear trend captures the overall direction.
- **Chronos-T5-Base** has the lowest MAPE among ML models (15.42%) despite being zero-shot.
- **SARIMA** performs worst due to the 2021 gap breaking the seasonal continuity.
- **XGBoost overfits** with only 51 training samples.

7 6. Tối ưu mô hình

7.1 6.1 GridSearchCV cho Random Forest

Hyperparameters tuned: `n_estimators` (100, 200, 300), `max_depth` (5, 10, 15, None), `min_samples_split` (2, 5, 10). 3-fold cross-validation.

7.2 6.2 RandomizedSearchCV cho XGBoost

50 random combinations from: `n_estimators` (100-500), `max_depth` (3-9), `learning_rate` (0.01-0.2), `subsample` (0.7-1.0), `colsample_bytree` (0.7-1.0).

Result: Optimization provided marginal improvement for RF but **made XGBoost worse** — overfitting on the small training set. This confirms that with 51 samples, simpler models are preferred.

7.3 6.3 Đặc trưng bên ngoài (Tỷ giá + Chính sách visa)

Exchange rates (VND vs KRW, CNY, USD, JPY, TWD, MYR) were fetched from Yahoo Finance. Visa policy indicators were manually encoded: - `visa_evisa`: E-visa available (2017+) - `visa_evisa_full`: E-visa for all countries, 90-day (2023 Q3+) - `covid_restrict`: Travel restriction index (0-1)

Result: External features improved LR slightly (MAE reduced ~5%) but made RF/XGB worse due to overfitting. `lag_1` and `rolling_mean_4` remain the dominant features (~73% importance). The post-COVID structural break remains the fundamental challenge.

8 7. Dự đoán tương lai




Figure 8: Figure 8: SARIMA forecast for next 4 quarters

Quarter	Forecast	95% Confidence Interval
2026 Q3	4,157,874	[2,764,158 — 5,551,591]
2026 Q4	4,156,459	[2,435,914 — 5,877,004]
2027 Q1	4,129,710	[2,167,419 — 6,092,001]
2027 Q2	4,129,570	[1,962,482 — 6,296,659]

Note: The very wide confidence intervals reflect fundamental uncertainty. SARIMA cannot capture the growth trend visible in recent quarters (6M+ in 2025-2026) and reverts toward the historical mean (~4M).

Per-quarter accuracy (best models):

Quarter	Actual	Best Model	Prediction	Error
2024 Q2	3,893,572	Chronos	3,602,994	-7.5%
2024 Q3	3,656,240	XGBoost	3,686,331	+0.8%
2024 Q4	4,428,526	LR	4,030,040	-9.0%
2025 Q1	5,408,927	LR	4,288,777	-20.7%
2026 Q1	6,058,711	LR	4,708,762	-22.3%

Models perform well on “normal” quarters (Q2-Q3) but severely underestimate the surge quarters (Q1 of 2025-2026). This is the **post-COVID structural break** problem.




Figure 9: Predicted vs Actual (test set detail)

9 8. Tổng kết

9.1 8.1 Kết quả chính

1. **Sai lệch phủ sóng là đáng kể:** Only 11-12 countries reported during 2009-2011 vs 30+ from 2012. Raw aggregate totals are misleading; growth rates should be used for fair comparison.
2. **Trung Quốc và Hàn Quốc chiếm ưu thế** the tourism market, but emerging markets (Hong Kong, Spain, Italy, Philippines) grew fastest during 2012-2019.
3. **Mùa vụ mạnh:** Q1 luôn có lượng khách cao nhất (ảnh hưởng Tết Nguyên Đán).
4. **Linear Regression hiệu quả đáng ngạc nhiên** with only 51 training samples, achieving the lowest MAE (668K) and best R^2 (-0.11). More complex models overfit.
5. **Không mô hình nào dự đoán tốt sự phục hồi hậu COVID.** All R^2 values are negative. The structural break is invisible to history-based models.
6. **CIR# (mô hình SDE tiên tiến) thất bại trên dữ liệu này** due to insufficient observations, mean-reversion assumption violation, and quarterly granularity. This is a valuable negative finding.
7. **Đặc trưng bên ngoài (tỷ giá, chính sách visa) cải thiện rất nhỏ** for LR but not for tree-based models with limited data.

9.2 8.2 Hạn chế

1. **Tập huấn luyện nhỏ** (51 quan sát theo quý sau khi loại bỏ 2021)
2. **Khoảng trống 2021** phá vỡ tính liên tục chuỗi thời gian
3. **Thiếu đặc trưng bên ngoài:** GDP, công suất bay, Google Trends, giá dầu
4. **Sự không nhất quán về phủ sóng quốc gia** (2009-2011 only 11-12 countries)

9.3 8.3 Hướng phát triển

1. **Dữ liệu theo tháng** để tăng kích thước mẫu và nắm bắt mùa vụ tốt hơn
2. **Chỉ báo dẫn đầu bên ngoài:** GDP quốc gia nguồn, tỷ giá, khối lượng tìm kiếm Google Trends, công suất đường bay
3. **Mô hình theo từng quốc gia** thay vì tổng hợp (different recovery trajectories)

4. **Phương pháp ensemble** kết hợp LR (xu hướng) với Chronos (nhận dạng mẫu)
5. **Mô hình chuyển đổi chế độ** that explicitly handle the pre-COVID / during-COVID / post-COVID transitions
6. **Dashboard tương tác** for real-time tourism monitoring and forecasting

10 Tài liệu tham khảo

1. Clements, A.E., et al. (2024). “Forecasting disrupted tourism demand: the CIR# model.” *Tourism Review*, 79(2), 445-470.
2. Clements, A.E., et al. (2023). “The CIR# model for time series forecasting.” *Technological and Economic Development of Economy*, 29(5), 1403-1427.
3. Scikit-learn documentation: <https://scikit-learn.org/>
4. XGBoost documentation: <https://xgboost.readthedocs.io/>
5. Statsmodels SARIMA: <https://www.statsmodels.org/>
6. Chronos (Amazon): <https://github.com/amazon-science/chronos-forecasting>
7. Yahoo Finance (exchange rate data): <https://finance.yahoo.com/>
8. Vietnam General Statistics Office (GSO): <https://www.gso.gov.vn/>