

Phân tích và Dự đoán Lượng Khách Du Lịch Quốc tế Đến Việt Nam

Báo cáo Cuối Kỳ — Lập trình Phân tích Dữ liệu với Python

dnng-nguyn

Tháng 7, 2025

1 Mục lục

1. Giới thiệu đề tài
2. Thu thập dữ liệu
3. Tiền xử lý dữ liệu
4. Phân tích và khám phá dữ liệu (EDA)
5. Xây dựng mô hình dự đoán
6. Tối ưu mô hình
7. Dự đoán tương lai
8. Tổng kết

2 1. Giới thiệu đề tài

2.1 1.1 Đặt vấn đề bài toán

Ngành du lịch là một trong những ngành kinh tế quan trọng của Việt Nam, đóng góp đáng kể vào GDP và tạo ra hàng triệu việc làm. Trong những năm gần đây, Việt Nam đã nổi lên như một điểm đến hấp dẫn trong khu vực Đông Nam Á, thu hút lượng lớn khách quốc tế từ nhiều quốc gia khác nhau.

Tuy nhiên, lượng khách du lịch quốc tế chịu ảnh hưởng của nhiều yếu tố phức tạp: tình hình kinh tế toàn cầu, chính sách visa, tỷ giá hối đoái, sự cạnh tranh từ các quốc gia láng giềng, và đặc biệt là đại dịch COVID-19 năm 2020–2021. Việc hiểu rõ các xu hướng, mô hình mùa vụ, và mối quan hệ giữa các thị trường nguồn là điều cần thiết để hoạch định chiến lược phát triển du lịch hiệu quả.

Đại dịch COVID-19 đã tạo ra một khoảng trống dữ liệu lớn (năm 2021 hoàn toàn không có dữ liệu trong các file báo cáo), gây thách thức đáng kể cho việc phân tích liên tục và xây dựng mô hình dự đoán.

2.2 1.2 Mục tiêu đề tài

Mục tiêu phân tích (Analytical):

- Phân tích xu hướng tổng thể lượng khách quốc tế đến Việt Nam trong giai đoạn 2008–2026.
- Xác định các quốc gia nguồn khách hàng đầu và sự thay đổi thứ hạng qua các năm.
- Phát hiện các mô hình mùa vụ (seasonality) trong lượng khách theo quý.
- Phân tích mối tương quan giữa các thị trường nguồn khách.
- Đánh giá tác động của đại dịch COVID-19 đến ngành du lịch Việt Nam.

Mục tiêu dự đoán (Predictive):

- Xây dựng các mô hình học máy để dự đoán lượng khách quốc tế theo quý.
- So sánh hiệu quả giữa các phương pháp: Linear Regression, Random Forest, XGBoost, SARIMA và Chronos-T5.
- Tối ưu hóa siêu tham số để cải thiện độ chính xác của mô hình.
- Dự đoán lượng khách cho 4 quý tiếp theo kèm theo khoảng tin cậy.

2.3 1.3 Phạm vi và nguồn dữ liệu

- **Đối tượng phân tích:** Lượng khách quốc tế đến Việt Nam, phân theo quốc gia nguồn và theo quý (Q1–Q4).
- **Thời gian:** Giai đoạn 2008–2026, với lưu ý năm 2021 không có dữ liệu (ảnh hưởng của đại dịch COVID-19).
- **Quốc gia nguồn:** 40 quốc gia/vùng lãnh thổ.
- **Nguồn dữ liệu:** Bốn file báo cáo dạng HTML-Excel (.xls) từ Tổng cục Thống kê.

2.4 1.4 Công cụ và thư viện sử dụng

- **Ngôn ngữ lập trình:** Python 3
- **Xử lý dữ liệu:** pandas, numpy, lxml (phân tích HTML)
- **Trực quan hóa:** matplotlib, seaborn
- **Xây dựng mô hình:** scikit-learn, xgboost, statsmodels (SARIMA), chronos-forecasting (Chronos-T5)
- **Môi trường:** Jupyter Notebook
- **Quản lý phiên bản:** Git, GitHub

3 2. Thu thập dữ liệu

3.1 2.1 Nguồn dữ liệu

Dữ liệu được cung cấp dưới dạng 4 file báo cáo HTML-Excel, mỗi file chứa thông tin lượng khách quốc tế đến Việt Nam cho một quý cụ thể:

File	Quý	Số quốc gia	Ghi chú
quy1-cacnuoc.xls	Q1	38	Bắt đầu từ năm 2009
quy2-cacnuoc.xls	Q2	39	Bắt đầu từ năm 2009
quy3-cacnuoc.xls	Q3	40	Bắt đầu từ năm 2008
quy4-cacnuoc.xls	Q4	38	Bắt đầu từ năm 2008

3.2 2.2 Cấu trúc dữ liệu và thách thức

Các file `.xls` này không phải là file Excel nhị phân thực sự, mà là file HTML có phần mở rộng `.xls` — một kỹ thuật phổ biến để tạo file “Excel” từ web. Cấu trúc HTML có một số đặc điểm gây thách thức:

Thứ nhất, dữ liệu không nằm trong các thẻ `<td>` theo cách thông thường. Các giá trị số liệu nằm dưới dạng text nodes giữa các thẻ `<td>` rỗng. Điều này khiến `pd.read_html()` không thể trích xuất chính xác — cần xây dựng bộ phân tích tùy chỉnh bằng `lxml`.

Thứ hai, các file không đồng nhất: Q3 và Q4 có dữ liệu từ 2008, Q1/Q2 chỉ từ 2009. Cột năm 2021 hoàn toàn vắng mặt.

Thứ ba, định dạng số sử dụng dấu chấm làm phân cách hàng nghìn (ví dụ: `104.520 = 104,520`).

3.3 2.3 Cách xử lý

Nhóm xây dựng bộ phân tích HTML tùy chỉnh bằng `lxml`: phân tích cây DOM, trích xuất text nodes từ thẻ `<td>`, chuyển đổi định dạng số, và hợp nhất thành DataFrame duy nhất.

Xác minh: Quốc gia “Hoa Kỳ” năm 2009, quý 1 = 104,520 lượt khách — khớp với dữ liệu mẫu.

Sau hợp nhất: **1,894 bản ghi, 40 quốc gia, 18 năm** (2008–2026, không bao gồm 2021).

4 3. Tiền xử lý dữ liệu

4.1 3.1 Làm sạch dữ liệu

- **Loại bỏ hàng “Totals”** — hàng tổng cộng không phải quốc gia riêng lẻ.
- **Kiểm tra trùng lặp** — không có bản ghi trùng lặp.
- **Chuẩn hóa tên quốc gia** — giữ nguyên tiếng Việt, đã nhất quán.

4.2 3.2 Xử lý giá trị thiếu

Các ô không có dữ liệu được điền bằng 0. Điều này hợp lý vì không có dữ liệu có nghĩa là không có khách từ quốc gia đó.

Sau xử lý: `df_complete` có **2,880 bản ghi** ($40 \text{ quốc gia} \times 18 \text{ năm} \times 4 \text{ quý}$).

4.3 3.3 Trích xuất đặc trưng (Feature Engineering)

- **Biến thời gian:** `quarter_num` (1–4), `time_idx` ($\text{năm} + \text{quý}/4$)
- **Đặc trưng trễ:** `lag_1`, `lag_2`, `lag_4` — giá trị quý trước
- **Trung bình trượt:** `rolling_mean_4` — TB 4 quý gần nhất
- **Chia train/test:** Train 2023, Test 2024

5 4. Phân tích và khám phá dữ liệu (EDA)

5.1 4.1 Xu hướng tổng thể




Figure 1: Hình 1: Lượng khách quốc tế đến Việt Nam theo năm (2008–2026)

Lượng khách tăng trưởng mạnh từ 3.8 triệu (2009) lên 18.0 triệu (2019) — tăng gần 5 lần. Năm 2020 giảm mạnh xuống 3.7 triệu do COVID-19. Phục hồi từ 2022, đạt 21.2 triệu năm 2025 — vượt mức trước đại dịch.

5.2 4.2 Top 10 quốc gia nguồn khách

- **Trung Quốc** (41.7 triệu) — thị trường lớn nhất
- **Hàn Quốc** (33.0 triệu) — tăng trưởng mạnh nhất
- **Nhật Bản** (10.1 triệu), **Đài Loan** (9.7 triệu), **Hoa Kỳ** (9.1 triệu)

5.3 4.3 Tính mùa vụ

Quý 1 có lượng khách cao nhất (Tết Nguyên Đán, năm mới). Quý 4 có độ biến động lớn nhất.

5.4 4.4 Tương quan giữa các quốc gia nguồn

Trung Quốc–Đài Loan tương quan mạnh (0.89). Hoa Kỳ tương quan thấp với các thị trường châu Á.

5.5 4.5 Xu hướng theo từng quốc gia

Hàn Quốc phục hồi nhanh nhất sau COVID-19. Trung Quốc chịu tác động nặng nề nhất.




Figure 2: Hình 2: Top 10 quốc gia nguồn khách hàng đầu




Figure 3: Hình 3: Phân tích mùa vụ — Lượng khách trung bình theo quý




Figure 4: Hình 4: Ma trận tương quan giữa 5 quốc gia nguồn lớn nhất



Figure 5: Hình 5: Xu hướng lượng khách theo từng quốc gia (Top 5)

6 5. Xây dựng mô hình dự đoán

6.1 5.1 Linear Regression (Hồi quy tuyến tính)

Linear Regression giả định mối quan hệ tuyến tính giữa biến đầu vào và biến mục tiêu. Mô hình tìm đường thẳng phù hợp nhất bằng cách tối thiểu hóa tổng bình phương sai số.

Đặc trưng đầu vào: năm, số thứ tự quý, chỉ số thời gian, lag_1, lag_4, rolling_mean_4.

6.2 5.2 Random Forest Regression

Random Forest kết hợp nhiều cây quyết định, mỗi cây huấn luyện trên mẫu bootstrap ngẫu nhiên. Kết quả là trung bình dự đoán của tất cả cây. Giảm overfitting so với cây đơn lẻ.

6.3 5.3 XGBoost Regressor

XGBoost xây dựng cây quyết định tuần tự, mỗi cây mới sửa lỗi cây trước. Nổi tiếng với tốc độ nhanh và kết quả xuất sắc trong các cuộc thi khoa học dữ liệu.

6.4 5.4 SARIMA (Mô hình chuỗi thời gian)

SARIMA kết hợp tự hồi quy (AR), lấy sai phân (I), trung bình trượt (MA) và mùa vụ (S). Phù hợp với dữ liệu có tính mùa vụ quarterly. Năm 2021 được loại bỏ khỏi chuỗi.

6.5 5.5 CIR# — Mô hình Ngẫu nhiên Vi phân (Stochastic Differential Equation)

Giới thiệu thuật toán:

CIR# (Cox-Ingersoll-Ross Sharp) là mô hình dự báo chuỗi thời gian dự trên phương trình vi phân ngẫu nhiên (SDE), được giới thiệu trong nghiên cứu của Clements et al. (2023, 2024). Mô hình mở rộng CIR kinh điển (ban đầu dùng cho lãi suất) bằng cách:

1. **Phân vùng dữ liệu** (data partitioning): chia chuỗi thành các subsample để nắm bắt thay đổi phương sai và các bước nhảy (jumps).
2. **Lọc ARIMA**: thay vì dùng nhiễu Brownian Motion (dW), mô hình sử dụng phần dư chuẩn hóa từ mô hình ARIMA tối ưu — giúp nhiễu thích ứng với mẫu cục bộ.
3. **Biến đổi Johnson**: phần dư được biến đổi để đảm bảo nhiễu trắng Gauss.
4. **Suy luận Milstein**: sử dụng dạng Milstein để giải tích SDE:

$$dr(t) = \kappa(heta - r(t))dt + \sigma\sqrt{r(t)}dW(t)$$

Trong đó κ là tốc độ hồi quy trung bình, $heta$ là giá trị dài hạn, σ là biến động.

Nghiên cứu gốc báo cáo kết quả xuất sắc trên dữ liệu du lịch Ý bị gián đoạn bởi COVID-19: MAPE 1.18% (giảm ~70% so với SARIMA và Holt-Winters). Đặc biệt, mô hình hoạt động tốt trong giai đoạn COVID (MAPE 1.69%).

Ứng dụng trong bài toán:

Áp dụng CIR# với các tham số: - Cửa sổ trượt $M = 8$ quý (tương đương $M = 12$ tháng trong nghiên cứu gốc) - ARIMA(p,q) tối ưu theo AIC trên mỗi cửa sổ (p,q $\in [0,2]$) - Phù hợp tham số CIR bằng bình phương tối thiểu trên mỗi cửa sổ - Dự báo một bước bằng suy luận Milstein với nhiễu từ phần dư ARIMA

Kết quả:

CIR# cho kết quả **rất kém** trên dữ liệu du lịch Việt Nam:

- **MAPE ~183%** — tồi tệ hơn tất cả các mô hình khác

- Dự đoán dao động mạnh quanh giá trị 0, không nắm bắt được xu hướng
- Giai đoạn COVID dự đoán giá trị âm hoặc gần 0

Tại sao CIR# không phù hợp:

Mặc dù CIR# xuất sắc trên dữ liệu du lịch Ý (288 quan sát hàng tháng), mô hình không phù hợp với bài toán Việt Nam vì:

1. **Dữ liệu quá ngắn:** Chỉ 55 quý (vs 288 tháng trong nghiên cứu gốc). Cửa sổ trượt $M=8$ lấy mất 15% dữ liệu, không đủ để fit CIR chính xác.
2. **Giả định hồi quy trung bình:** CIR SDE kéo $r(t)$ về (giá trị dài hạn). Du lịch Việt Nam có xu hướng tăng mạnh liên tục, không hồi quy — mâu thuẫn cơ bản với giả định mô hình.
3. **Sốc COVID quá lớn:** Giảm ~80% rồi phục hồi hoàn toàn. Biến đổi log-lợi suất khuếch đại nhiễu trong thành phần $\sqrt{r}$, gây dao động hoang dã.
4. **Dữ liệu quarterly vs monthly:** Nghiên cứu gốc dùng dữ liệu hàng tháng cho phép nắm bắt tính mùa vụ tốt hơn và có nhiều quan sát hơn trên mỗi cửa sổ.

Bài học: Không phải mọi mô hình SOTA đều phù hợp với mọi bộ dữ liệu. CIR# là lựa chọn xuất sắc cho chuỗi thời gian tài chính/kinh tế có tính hồi quy trung bình, nhưng không phù hợp cho chuỗi có xu hướng tăng mạnh và sốc cấu trúc lớn. Đây là minh chứng cho tầm quan trọng của việc benchmark trên dữ liệu thực tế.

6.6 5.6 Chronos-T5 (Foundation Model)

Chronos là mô hình foundation model của Amazon, pretrained trên hàng triệu chuỗi thời gian. Hoạt động theo nguyên lý **zero-shot forecasting** — không cần huấn luyện lại. Cung cấp dự đoán xác suất với khoảng tin cậy.

Thử nghiệm 4 kích thước: Tiny (8M), Small (46M), Base (200M), Large (710M). Chạy trên CPU.

6.7 5.7 So sánh hiệu suất các mô hình




Figure 6: Hình 6: So sánh hiệu suất các mô hình dự đoán

Mô hình	MAE	RMSE	R²
LR	1,099,063	1,448,419	0.4846
RF	1,098,133	1,548,464	0.4109
XGB	1,037,611	1,467,481	0.4709
SARIMA	1,548,896	2,096,619	-0.0799
Chronos	1,412,524	2,184,660	-0.1725

Mô hình	MAE	RMSE	R ²
RF (opt)	1,081,460	1,538,767	0.4183
XGB (opt)	1,092,469	1,553,966	0.4067

Nhận xét:

- **Chronos-T5-Base** cho MAE thấp nhất (0.92M) — thấp hơn tất cả mô hình truyền thống.
- **Linear Regression** cho R² tốt nhất (0.48) — nắm bắt xu hướng tuyến tính.
- **SARIMA** cho kết quả kém nhất do khoảng trống dữ liệu 2021 phá vỡ tính liên tục.
- **Random Forest** và **XGBoost** không vượt trội hơn LR với dữ liệu nhỏ (55 quý).

Tại sao Base tốt hơn Large? Với chỉ 55 điểm dữ liệu, mô hình lớn hơn “overthinking” — tìm mẫu hình phức tạp trong khi chỉ có xu hướng tăng đơn giản bị gián đoạn bởi COVID-19. Prior của model lớn (từ tài chính, thời tiết...) không phù hợp với du lịch Việt Nam.

7 6. Dự đoán vs Thực tế (2024–2026)




Figure 7: Hình 6b: Dự đoán vs Thực tế — Tập test

Quý	Thực tế	LR	Sai lệch	XGBoost	Sai lệch	Chronos	Sai lệch
2024 Q1	4,642,798	3,893,818	-16.1%	3,738,777	-19.5%	3,784,412	-18.5%
2024 Q3	3,873,045	4,236,586	+9.4%	3,827,625	-1.2%	3,965,012	+2.4%
2025 Q1	6,018,708	4,594,127	-23.7%	4,506,910	-25.1%	4,088,150	-32.1%
2026 Q1	6,762,175	5,070,457	-25.0%	4,506,910	-33.4%	4,334,424	-35.9%

Thách thức “hậu COVID-19”: Không mô hình nào — kể cả Chronos foundation model — có thể dự đoán chính xác sự phục hồi hậu đại dịch. Dữ liệu huấn luyện kết thúc 2023 với ~5 triệu, nhưng 2025–2026 bùng nổ lên 6–7 triệu. Đây là structural break mà mô hình dựa vào lịch sử không thể nắm bắt.

8 7. Dự đoán tương lai




Figure 8: Hình 7: Dự đoán lượng khách 4 quý tiếp theo

Dự đoán SARIMA cho 4 quý tiếp theo:

Quý	Dự đoán	Khoảng tin cậy 95%
2027 Q1	1,421,545	[-247,180 — 3,090,271]
2027 Q2	-209,643	[-3,479,627 — 3,060,341]
2027 Q3	-1,549,742	[-5,812,211 — 2,712,728]
2027 Q4	-1,132,213	[-6,199,123 — 3,934,697]

Lưu ý: Khoảng tin cậy rất rộng, phản ánh mức độ không chắc chắn cao do COVID-19 và dữ liệu hạn chế.

9 8. Tổng kết

9.1 8.1 Kết quả đạt được

1. Phân tích thành công dữ liệu du lịch 2008–2026, chỉ ra xu hướng tăng trưởng và tác động COVID-19.
2. Xác định Trung Quốc và Hàn Quốc là thị trường nguồn lớn nhất.
3. Phát hiện tính mùa vụ: Q1 cao nhất.
4. Xây dựng 5 mô hình, Chronos-T5-Base cho MAE thấp nhất.
5. Dự đoán 4 quý tiếp theo với khoảng tin cậy.

9.2 8.2 Hạn chế

1. Dữ liệu hạn chế (55 quý huấn luyện).
2. Khoảng trống 2021 phá vỡ tính liên tục chuỗi thời gian.
3. Thiếu đặc trưng bên ngoài (chính sách visa, tỷ giá...).
4. Dự đoán SARIMA không ổn định.

9.3 8.3 Hướng phát triển

1. Thu thập dữ liệu theo tháng để tăng mẫu.
2. Bổ sung đặc trưng bên ngoài (visa, tỷ giá, sự kiện du lịch).
3. Thử nghiệm Prophet, LSTM.
4. Dự đoán theo từng quốc gia riêng lẻ.
5. Xây dựng dashboard tương tác.